

Principales problemas encontrados

1.335

Valores faltantes

en 9 de las 11 variables. La más afectada: Attendance (224 casos, 4,39%).

1

100

Registros duplicados

filas 100% idénticas (mismo StudentID y mismos datos) — 1,96% del dataset.

2

134

Inconsistencias de dominio

63 numéricas fuera de rango (ej. Attendance < 0, notas > 10) + 71 categorías con formato no estandarizado.

3

372

Estudiantes con outliers (IQR)

7,29% del total; 54 de ellos caen además fuera del dominio válido (inválidos, no solo extremos).

4

Regla cruzada: SleepHours + InternetHours supera las 24 h/día en 96 registros (1,88% del dataset).

Principales decisiones de tratamiento

1

Duplicados eliminados

Las 100 filas 100% idénticas se descartan: no aportan información nueva y podrían sesgar el modelo.

2

Fuera de dominio → NaN → imputado

Valores imposibles (asistencia negativa, notas > 10, horas > 24) se marcan como faltantes y se imputan.

3

Imputación numérica adaptativa

Media si la variable es simétrica; mediana si hay asimetría, > 1% de outliers IQR o diferencia media-mediana > 2% ("efecto Bill Gates").

4

Imputación categórica con la moda

Scholarship y Program se completan con su categoría más frecuente.

5

Regla cruzada Sleep + Internet ≤ 24 h

Los 96 registros que la violan se corrigen reemplazando ambas variables por su mediana global.


6

Outliers válidos se conservan

Solo se corrige lo fuera de dominio; StudyHours, Age y PreviousGPA mantienen su variabilidad real.


Principales resultados del EDA

FinalGrade (escala 1-10) es la variable de resultado académico a explicar



- Beca
- Programa académico
- Estudio y asistencia
- Lectura general

Correlación de cada variable con FinalGrade



Estado final de la calidad de los datos

Dataset original vs. dataset tratado, tras aplicar el pipeline de limpieza y transformación

INDICADOR	ORIGINAL		TRATADO	
Registros <i>100 duplicados fuera</i>	5.100	→	5.000	✓
Variables <i>encoding de categóricas</i>	11	→	15	✓
Valores faltantes	1.335	→	0	✓
Registros duplicados	100	→	0	✓
Inconsistencias de dominio	134	→	0	✓
Outliers inválidos	55	→	0	✓

Dataset limpio: sin duplicados, inconsistencias ni valores faltantes — listo para modelado predictivo.